

AVANCE DEL PROYECTO FINAL

Operation Suite Intelligence

Sistema Inteligente de Salud, Detección de Anomalías y
Priorización Operativa

Curso	Ciencia de Datos II
Docente	Ing. Naomy Ríos
Estudiante / equipo	Miguel Ángel Carranza Avilez — trabajo individual
Proyecto base	Operation Suite
Fecha de entrega	4 de septiembre de 2026

1. Descripción del proyecto original

Operation Suite es una plataforma web para centralizar la administración y supervisión de herramientas de producción gráfica que se ejecutan localmente en Adobe Illustrator. Su finalidad no es procesar arte en la nube: controla de forma segura quién puede utilizar cada herramienta, desde qué estación autorizada y dentro de qué cuenta o workspace.

La solución integra una aplicación web, Firebase Authentication, Cloud Firestore, Cloud Functions, un Local Bridge de alcance local y un panel CEP para Adobe Illustrator. Los motores de **Clean Vector PRO** y **Sep Maker PRO** permanecen ejecutándose en la computadora del artista. Operation Suite administra cuentas, usuarios, membresías, roles, equipos, workspaces, herramientas, licencias, asignaciones y estaciones de trabajo.

Problema original que resuelve. En un entorno de producción gráfica, las herramientas, automatizaciones, configuraciones por cliente y accesos pueden estar fragmentados entre estaciones y usuarios. Operation Suite aporta autorización centralizada, aislamiento por workspace, estandarización, trazabilidad y telemetría operacional segura.

Arquitectura operacional

Super Administrator → Web App / consola administrativa → Cloud Functions auditadas → Firestore con acceso default-deny → catálogo autorizado de la estación → Local Bridge local → panel CEP → Clean Vector PRO o Sep Maker PRO → resultado sanitizado → ExecutionEvent V1 y agregados diarios → tableros según rol

Por privacidad, Operation Suite no registra ni analizará nombre, ruta o contenido de archivos, arte, configuraciones técnicas de clientes, direcciones MAC, correos personales, credenciales ni secretos. La telemetría conserva únicamente datos operacionales mínimos y autorizados.

2. Problema seleccionado

Operation Suite registra ejecuciones de herramientas con duración, resultado, timestamps, versión, workspace y estación autorizada. Estos datos informan *qué ocurrió*, pero no identifican automáticamente si una ejecución fue inusual ni cuál entidad debe revisarse primero.

Una ejecución puede terminar con `success` y, aun así, tardar mucho más que su comportamiento normal. Por ejemplo, una acción de Sep Maker PRO que normalmente toma entre 8 y 15 segundos podría tardar 47 segundos; el estado de éxito no revela esa posible degradación.

Pregunta central: ¿Cómo puede el análisis de telemetría operacional permitir la identificación temprana de comportamientos anómalos y la priorización de workspaces, dispositivos o herramientas que requieren intervención dentro de Operation Suite?

3. Objetivos

Objetivo general

Construir **Operation Suite Intelligence**, un componente de Ciencia de Datos que analice telemetría operacional segura para detectar anomalías, calcular salud operativa y priorizar workspaces, dispositivos y herramientas que requieren atención dentro de Operation Suite.

Objetivos específicos

- 1. Diseñar un dataset híbrido, trazable y privado a partir de telemetría operacional y datos sintéticos reproducibles.
- 2. Implementar un proceso ETL que extraiga, normalice, limpie y prepare los datos para análisis, entrenamiento, evaluación y visualización.
- 3. Realizar análisis exploratorio de ejecuciones, duración, resultado, herramientas, workspaces, plataforma y tendencias temporales.
- 4. Identificar y evaluar una técnica de detección de anomalías basada en Isolation Forest frente a una línea base estadística robusta.
- 5. Diseñar un Operational Health Score y un Priority Engine explicables que apoyen decisiones administrativas sin evaluar el desempeño individual de empleados.

4. Dataset

Fuente y tipo

La fuente operacional es el contrato implementado `ExecutionEvent V1`. Para el avance se generó un dataset reproducible de **1,440 ejecuciones sintéticas**, distribuidas en 90 días y dos grupos homogéneos: Clean Vector PRO / CLEAN ART y Sep Maker PRO / Apply. La estructura también admite ejecuciones reales controladas cuando sean autorizadas.

Origen	Descripción	Uso
SYNTHETIC	Registros reproducibles, con patrones normales y anomalías documentadas.	Volumen, EDA y evaluación académica controlada.
REAL_CONTROLLED	Ejecuciones sanitizadas y autorizadas realizadas para la validación académica.	Contrastar la representación con telemetría real, sin datos productivos sensibles.

Transparencia: el avance usa únicamente registros SYNTHETIC. No se presentan como telemetría productiva real ni se usaron datos empresariales, archivos de Illustrator o información personal.

Estructura y diccionario de datos

Campo	Tipo	Descripción y uso
execution_id	Texto	Identificador único; deduplicación y trazabilidad.
account_id, workspace_id, device_id, actor_uid	Texto opaco	Contexto, filtros y agrupación; no son features iniciales del modelo.
tool_id, tool_version, action	Categorico	Herramienta, versión y acción; permiten segmentar grupos comparables.
status	Categorico	success, failure o cancelled; EDA y Health Score, no feature inicial.
error_code	Categorico / nulo	Código seguro y cerrado de error; explicación y EDA, nunca mensajes libres.
duration_ms	Entero	Duración en milisegundos; señal principal de anomalía.
started_at, completed_at, received_at	Timestamp UTC	Validación temporal, tendencias y variables derivadas.
source, host_version, suite_version, device_platform	Categorico	Trazabilidad, análisis por plataforma y posibles variables candidatas.
data_origin	Categorico	Separa estrictamente SYNTHETIC de REAL_CONTROLLED.
duration_seconds, log_duration, hour_of_day, day_of_week	Derivado	Variables creadas por el ETL para EDA y modelado.
expected_anomaly	Booleano académico	Etiqueta sintética conocida, utilizada solo después del scoring para evaluación; nunca como feature.

5. Proceso de Ciencia de Datos

5.1 Obtención

La obtención se diseñó para partir de eventos de telemetría autorizados y de las colecciones mínimas necesarias para contextualizarlos: ejecuciones, agregados diarios, estaciones, workspaces y catálogo de herramientas. En esta entrega se utiliza un generador determinístico con IDs opacos, semilla documentada, patrones por herramienta y anomalías conocidas. No se conectó a Firebase productivo ni se leyó contenido de Illustrator.

5.2 ETL

Fase	Actividad aplicada	Resultado
Extract	Lectura del CSV sintético generado; el diseño admite posteriormente exportaciones sanitizadas autorizadas.	1,440 eventos fuente.
Transform	Validación de esquema, deduplicación por <code>execution_id</code> , normalización de categorías, conversión de duración, validación de timestamps y creación de variables temporales y <code>log_duration</code> .	Dataset limpio y analítico.
Load	Persistencia local de dataset procesado, reporte de calidad, resumen EDA, scoring y resultados derivados.	Artefactos reproducibles, sin servicios externos.

1,440 registros generados	1,440 registros aceptados por ETL
0 registros rechazados	90 días cobertura temporal sintética

5.3 Limpieza

La limpieza diferencia un dato inválido de una anomalía válida. Se rechazan registros con identificadores o categorías fuera de la allow-list, duplicados conflictivos, campos obligatorios ausentes, timestamps no interpretables, finalización anterior al inicio, duración negativa o duración mayor al máximo contractual de doce horas.


Una ejecución lenta, fallida o cancelada que cumple el contrato **no se elimina**; podría contener precisamente la señal operacional que se desea detectar. Los nulos opcionales se conservan como ausencia explícita y los IDs opacos se excluyen de las features directas para evitar sesgo por alta cardinalidad.

5.4 EDA — análisis exploratorio inicial

Se exploraron volúmenes, estados, plataformas, duración por herramienta, percentiles, anomalías sintéticas conocidas y comportamiento temporal. Los resultados siguientes son evidencia inicial sobre el dataset sintético y no una afirmación sobre uso productivo.


Indicador	Resultado inicial
Ejecuciones por estado	1,325 success (92.0%), 75 failure y 40 cancelled.
Distribución por herramienta	667 ejecuciones de Clean Vector PRO y 773 de Sep Maker PRO.
Anomalías sintéticas documentadas	111; la mayoría mantiene success para validar que “éxito” no equivale siempre a “comportamiento normal”.
Duración — Clean Vector PRO	Mediana 4.428 s; percentil 95: 13.362 s.
Duración — Sep Maker PRO	Mediana 11.881 s; percentil 95: 38.850 s.

Figura 1. Distribución de ejecuciones por estado



Fuente: dataset sintético reproducible v0.1 (n = 1,440).

Figura 2. Duración por herramienta: mediana y percentil 95



La diferencia de escalas justifica segmentar el análisis por herramienta y acción.

6. Modelos utilizados — algoritmo identificado

Tipo de problema	Aprendizaje no supervisado para detección de anomalías operacionales.
Algoritmo identificado	Isolation Forest , entrenado inicialmente por grupos homogéneos de herramienta y acción.
Variable objetivo	No aplica como objetivo operacional tradicional. La etiqueta <code>expected_anomaly</code> existe solo para evaluar el dataset sintético después del scoring.
Feature inicial	<code>log_duration</code> , derivada de <code>duration_ms</code> . Las variables temporales, plataforma y versión serán candidatas únicamente si una ablación temporal demuestra mejora.
Features excluidas	<code>status</code> , <code>error_code</code> , <code>workspace_id</code> , <code>device_id</code> , <code>account_id</code> y <code>actor_uid</code> ; se usan para EDA, explicación o agrupación, no para que el modelo aprenda identidades o “fallo = anomalía”.
Evaluación	Separación cronológica 70/30, Precision, Recall y F1; comparación obligatoria con baseline robusto MAD/IQR.

Resultado preliminar y criterio de rigor: en el dataset sintético univariado, MAD/IQR superó a Isolation Forest. Por ello, ambos se conservarán como comparación y ninguna alerta automatizará decisiones. Isolation Forest sigue siendo el algoritmo seleccionado para la clase por su capacidad de identificar patrones inusuales sin requerir un historial real ampliamente etiquetado.

Conclusión del avance

El avance cumple con la definición del problema, objetivos, dataset, diccionario de datos, ETL, limpieza, EDA y la identificación del algoritmo solicitado. El valor agregado de Operation Suite Intelligence consiste en transformar telemetría segura en señales explicables: qué ejecución se comportó de forma inusual, qué workspace, dispositivo o herramienta requiere atención y por qué.

La siguiente etapa será validar con datos `REAL_CONTROLLED`, ampliar las visualizaciones académicas y, únicamente tras aprobación técnica separada, evaluar la integración de resultados derivados al dashboard exclusivo del Super Administrator.